

# pMRI国内外研究进展

Henry

2021 年 12 月 24 日

## 1 背景

磁共振成像(Magnetic Resonance Imaging, MRI)是一项无创的医学成像技术,该成像技术不仅不需要使用电离辐射,而且还可以得到分辨率和质量较高的病理图像,这些特性使得人体内一些器官结构、血管结构和其他生理特征都可以得到较好的可视化,因此MRI在临床上得到了广泛的应用。但是,MRI不同于计算机断层扫描(Computed Tomography, CT)等方法具有成像时间快的特性,该技术最大的障碍就是其数据采集时间过于缓慢,而且MRI设备一般都是比较密闭的空间,病人在接受扫描时可能因为空间过于密闭而导致的无法呼吸、幽闭恐惧症等。MRI技术的主要研究方向为缩短成像时间、提高成像质量,并行磁共振成像[1](parallel Magnetic Resonance Imaging, pMRI)技术是提高MRI速度的主要方法之一,其使用一组线圈,通过获取具有不同空间灵敏度的欠采样的数据去加速成像速度,但是该方法主要受限于线圈灵敏度信息,因为难以获取较为准确的灵敏度信息。

## 2 国内外研究现状

核磁共振成像技术主要分为两个步骤,分别是数据信号采集和图像重建,图像重建主要通过获取的欠采样的数据,重建出较为完整的图像。但是,受限于MRI设备和采样定理的缘故,采集数据耗费大量时间,得到的图像也很容易因为病人运动等原因产生伪影,因此众多学者致力于MRI快速成像重建的研究中,MRI图像重建方法主要分为三类:

第一类,基于图像域的重建方法,该方法需要明确知道MRI设备中线圈灵敏度的信息,通过灵敏度信息将该问题建模为一个逆问题,通过非线性优化算法等进行解决;

第二类,基于频率域( $k$ -空间)的重建方法,其灵敏度等信息隐式的存在于 $k$ -空间数据中,因此使用类似插值的方法估计 $k$ -空间缺失的数据;

第三类,基于深度学习的重建方法,该方法通过MRI成像模型,构造出相对应的损失函数和正则化方法,建立深度网络进行训练。

### 2.1 基于图像域的重建方法

pMRI系统使用一组阵列线圈同时进行采集数据,线圈阵列由多个线圈组成,用于采集不同空间位置上的信息,越接近线圈的区域上信号会更强,这种不同空间位置导致的信号强弱被称为线圈的灵敏度。在通常情况线圈的灵敏度未知,但是基于图像域的重建方法首先需要明确知道灵敏度,使得这一方向的大多数算法都受此影响,导致重建质量不佳。

图像中较为著名的重建算法为SENSitivity Encoding(SENSE)[2],其在图像域中对伪影进行去除,主要缺点是需要依赖于精确的灵敏度,因此估计出精确的灵敏度是SENSE类方法的重要步骤。例如,在JSENSE[3]、

TSENSE[4]和mSENSE[5]中, JSENSE算法将MRI图像重建问题转化为线圈灵敏度和图像的联合估计问题, 使用优化迭代算法进行交替求解; TSENSE提出了一种自适应灵敏度估计的方法, 用以提高精确度。尽管可以通过估计的方法得到线圈的灵敏度信息, 但是使用不够精确的灵敏度进行重建, 导致重建得到的图像容易受到噪声放大、伪影等影响, 此时可以使用正则化方法进行改良重建问题, 使解约束在某一个空间中, 得到较为稀疏的解。

在SENSE类重建方法中经常使用的正则化方法有Tikhonov正则化( $l_2$ 正则化)、全变差正则化(Total Variation, TV)、小波正则化和联合多种正则化方法等。在文[6]中提出一种快速求解TV正则化模型的算法, 虽然TV正则化的方法有助于去除伪影, 但是也有可能产生阶梯状伪影, 导致重建质量不佳, 使得医生难以通过该重建图像进行诊断病情。Total Generalize Variation(TGV)[7]的提出可以消除TV这一系列缺点, 从而提高图像质量。Knoll等人[8]使用二阶TGV进行约束, 减少了重建图像中的阶梯状伪影, 同时也提出一种非线性重建方法进行求解。随着压缩感知(Compressed Sensing, CS)等理论的研究深入, Lustig等人发现MRI图像是较为稀疏的, 如果使用适当的重建算法, 具有稀疏性的MRI图像将可以从任意采样的 $k$ -空间数据中得到恢复, 因此提出了CS-MRI[9], 该方法也奠定了CS与MRI相结合的算法框架。在CS-MRI这一框架下, Liang等人提出了一种新的快速成像算法, 其将SENSE和CS-MRI进行相结合, 称为CS-SENSE[10], 同时也奠定了CS理论和并行成像的算法理论框架。MRI重建模型使用CS理论可以得到较为稀疏的重建图像, 并且较好地进行了图像去噪和抑制伪影, 因此该算法框架被广泛应用于MRI图像重建问题上。

CS-MRI或CS-SENSE模型对目标图像进行稀疏变换, 对变换得到稀疏系数使用 $l_0$ 范数进行约束, 但是求解 $l_0$ 范数是NP难问题, 因此将 $l_0$ 范数转化为其最优凸近似 $l_1$ 范数, 最后使用非线性算法进行求解。CS-MRI或者CS-SENSE模型中, 常使用离散小波(Wavelet), 紧框架(Framelet)等进行稀疏变换。因为紧框架系统存在冗余性, 可以较好地对目标图像进行稀疏表示, 同时其也具有好的计算性质, 例如正交Haar紧框架则拥有完美重构的性质, 因此众多研究者常使用具有冗余性质的紧框架对图像进行稀疏变换。如Li等人提出一种基于二维正交Haar小波的紧框架系统, 称为DHF[11], 可用于检测图像水平, 垂直和 $\pm 45^\circ$ 方向上的边缘特征, 并提出了相应的求解算法。Liu等人也基于紧框架系统, 开发了投影迭代软阈值算法(pISTA)[12]和其加速版本pFISTA, 但是该作者没有证明其收敛准则, 而且其现有的单线圈收敛准则也不适用于并行成像版本, 因此Zhang等人[13]基于Liu的工作基础, 分析了pFISTA应用于并行成像的收敛性、提供应用于SENSE时的最优参数。

CS-SENSE在求解pMRI问题时体现了其优越性, 但是基本上不可能保证完全恢复, 文[14]中提出一种联合稀疏的pMRI重建模型JS-CS-SENSE, 进一步提升CS-SENSE模型的稀疏性, JS-CS-SENSE重建模型同时使用小波正则化和全变差正则化, 能够更加有效的提取先验信息, 同时也更好的克服了采样系统和稀疏化之间的相互一致性障碍, 联合稀疏的重建模型能够较好解决CS-SENSE模型的缺点, 但是也提升了计算的复杂性。在文[15]提出无校准(calibration-free)的联合稀疏编码算法, 该方法不需要ACS数据, 利用联合稀疏正则化的方法挖掘潜在的灵敏度信息, 将pMRI问题描述为一个 $l_2 - l_F - l_{2,1}$ 最优化问题, 使用F范数约束稀疏表示的误差,  $l_{2,1}$ 混合范数用于触发联合稀疏性。文[16]使用一种特征细化的方法, 利用特征描述符提取有用的信息, 结合CS-pMRI技术, 从而能够更好的保留图像细节, 并且提出一种新的特征描述技术, 由纹理描述符(texture descriptor, TD)和结构描述符(structure descriptor, SD)组成, 最后使用三种CS-pMRI重建算法测试该特征描述的有效性。文章[17]中提出了一种新的重建框架, 其利用虚拟共轭线圈(Virtual conjugate coil, VCC)[18]和wave编码技术, 用以改善重建质量。虚拟线圈是由真实物理线圈的共轭信号产生的, 能够提供额外的编码能力, 并且还能改善pMRI编码矩阵的病态情况。

在文章[19]提出了一种不同于小波变换、全变差等的稀疏表示方法, 可以自适应的学习稀疏变换, 称为字典学习(Dictionary Learning, DL)。字典学习着重于图像的局部结构, 用以增强图像的局部稀疏性, 但是通过挖掘图像局部信息所带来的是高昂的计算成本。在[20]一文中, 作者使用双紧框架提取稀疏变换, 将MRI图像分为光滑和非光滑部分, 对两个部分施加不同的正则化MRI。其针对光滑部分采用较为通用的 $l_1$ 正则化, 而为了保留非光滑部分的边缘结构和细节纹理等, 提出基于紧框架的曲线波 $l_{1,a}$ 正则化方法, 并且提供了自适应求解参数 $a$ 的算法。同样地, 由于CS-MRI获取图像特征的局限性, 文[21]中提出一种基于patch的非局部算子(PANO), 该算法首先通过欧式距离计

算patch之间的相似性，然后将相似的patch堆叠成3D结构，进行通过3D Haar小波进行提取特征。但是，该文算法最主要的缺点就是使用欧式距离进行衡量patch之间的相似性，因为通过该度量方式得到的patch，它们之间的很有可能不存在结构相似性，而仅仅只是像素值上的接近。

## 2.2 基于频率域( $k$ -空间)的重建方法

基于 $k$ -空间的重建方法与图像域方法的主要区别为，不需要明确知道线圈灵敏度信息，其信息隐含在 $k$ -空间数据中。Generalized autocalibrating partially parallel acquisitions (GRAPPA) [22]是较为著名的频率域重建算法，其将pMRI重建问题视作一个缺失值填充问题，挖掘 $k$ -空间存在的数据冗余性。GRAPPA较为重要的一步就是从 $k$ -空间中心一块全采样的数据(Auto Calibration Signal, ACS)中估计得到插值核，然后使用插值核和缺失点周围的已获取数据进行线性组合，从而估计出缺失值。但是GRAPPA重建质量不佳，因此Lustig等人基于GRAPPA的思想，提出了SPIRiT [23]算法，其主要使用了与GRAPPA中类似的方法计算出插值核，然后将问题构建为一个 $k$ -空间中对数据填充的逆问题，并且使用小波正则化对问题进行约束，纳入图像的先验知识进一步提升重建图像质量，提出了 $l_1$ -SPIRiT。随着SENSE类方法和GRAPPA方法的研究深入，一些学者也开始研究SENSE和GRAPPA两者之间的联系，Uecker [24]等人将GRAPPA和SENSE相结合，将其解约束在子空间中，对Calibration矩阵进行SVD分解，将分解结果的右奇异矩阵的特征向量作为灵敏度信息，提出'soft' SENSE模型，也基于CS-MRI的思想，对目标图像使用小波分解提取先验信息，将分解系数用 $l_1$ 范数进行约束。但是，ESPIRiT方法仍未考虑灵敏度的相位信息，估计得到的灵敏度仍不够精确，在[25]一文中，将ESPIRiT算法应用于物理和虚拟线圈数据中，提出了VCC-ESPIRiT，该算法利用了 $k$ -空间数据的共轭对称性，通过计算得到了含有图像绝对相位的线圈灵敏度信息，进一步提升了图像重建质量。文[26]也受到了ESPIRiT的启发，提出了EVLIVE (Extended NonLinear InVersion inspired by ESPIRiT)，该算法不需要ACS数据，并且使用非线性算法联合估计图像和相对应的线圈灵敏度，作者将联合估计问题推导为一个矩阵核范数最小化问题，并且解释了EVLIVE具有的低秩性质，最后通过实验表明EVLIVE对噪声和数据具有的鲁棒性。

GRAPPA重建算法的思想类似于插值，从ACS数据估计出插值核后通过线性组合的方式得到缺失点。在 $k$ -空间中存在另一种思想的重建算法，其通过构造一个Hankel矩阵，将pMRI问题建模为一个低秩矩阵补全问题，使用奇异值收缩算法进行求解。文[27]中提出了一种结构化低秩矩阵补全的算法SAKE，该算法不需要 $k$ -空间中的ACS即可恢复出完整数据，首先使用 $k$ -空间数据进行构建得到block Hankel矩阵，然后通过数据一致性和block Hankel矩阵的低秩性重建出完整图像数据。ALOHA [28]算法将pMRI和CS-MRI转换为使用结构化矩阵的 $k$ -空间低秩加权矩阵补全问题，基于ALOHA和SPIRiT的算法，Zhang等人提出STDLR-SPIRiT，该算法使用SPIRiT的插值核对 $k$ -空间数据进行校正，同时使用小波变换在 $k$ -空间水平方向和垂直方向上进行分解，然后对分解系数使用核范数约束其低秩的性质，该算法引入较多的正则项，大大提升了计算复杂度。Jingyuan Lyu [29]等人证明了自动校准数据和未获取数据之间的非线性关系，基于核估计的方法，提出了更为通用的非线性重建框架，相比于传统的GRAPPA，其使用非线性方法对缺失数据进行估计的重建算法更具有鲁棒性。Blaimer [30]等人使用虚拟共轭线圈，提出了phase-constraint GRAPPA，并且在GRAPPA进行校准的过程，对实际线圈和虚拟线圈数据施加不同的正则化系数，得到了比传统GRAPPA更好的重建效果。

## 2.3 基于深度学习的重建方法

近年来，机器学习和深度学习等方法快速发展，深度学习的方法也被应用于磁共振成像重建问题中。深度学习使用大量的数据进行训练，通过挖掘 $k$ -空间数据和目标图像之间的关系完成重建。MoDL [31]基于pMRI成像模型，提出基于卷积神经网络(CNN)正则化的重建模型，该模型使用CNN提取图像的先验信息，使用数值算法和神经网络训练相结合的方法提高重建质量。Luo等人根据最新提出的PixelCNN+ [32]，提出基于深度贝叶斯估计的重建模型 [33]，该模型通过贝叶斯定理，将MRI问题进行建模，通过最大化概率的方法完成对欠采样 $k$ -空间的重建。基

于ESPIRiT方法, 文[34]中提出DL-ESPIRiT, 设计一种基于(2+1)D的时空卷积神经网络, 先使用2D卷积核, 然后再使用1D卷积核, 产生了比直接使用3D卷积神经网络更好的重建效果。基于CS-MRI, Yang等人提出一种新的网络框架ADMM-Net[35], 该模型将ADMM算法结合卷积神经网络, 使用端到端的训练方法。Yang等人基于CS-MRI和生成性对抗神经网络(GAN), 提出一种新的重建模型DAGAN[36], 该模型在保留了图像较多细节的情况下并且拥有更高的重建质量, 而且其重建质量高于ADMM-Net。

GRAPPA作为传统的重建方法之一, 其思想也被众多学者纳入深度学习重建方法中。文[37]提出深度学习和并行成像相结合的GRAPPANet, 该网络框架包含两个卷积神经网络(CNN), 在它们两个之间使用传统的GRAPPA算法, 该框架将第一个CNN的结果作为输入, 经过GRAPPA处理后, 将处理结果通过第二个CNN进行训练, 模型训练流程如图1所示。相比于GRAPPA的线性插值方法, 文[38]提出Robust artificial neural networks for  $k$ -space interpolation(RAKI), 该算法使用深度网络对ACS数据进行训练得到插值核, 进而通过非线性估计的方法计算得到缺失数据。文[39]提出一种基于深度残余网络的多线圈并行成像重建算法(DeepcomplexMRI), 该算法无需依赖于线圈

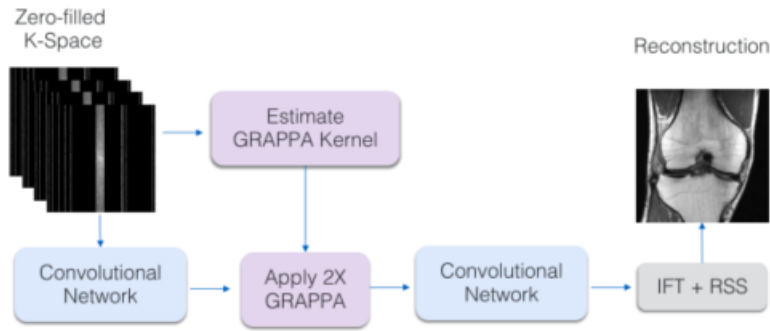


Figure 1: The GRAPPANet model

灵敏度和图像的先验知识, 使用复卷积网络对MRI数据的实部和虚部分别训练, 并且在训练过程中施加 $k$ -空间数据一致性约束。

但是从目前来说, 基于深度学习的方法仍未得到广泛应用, 最主要的原因数据难以获取, 而且训练得到的模型泛化能力不够强, 当数据之间差异较大时, 模型的重建结果质量较差, 同时图像重建质量也容易到MRI设备参数的影响。



## References

- [1] Anagha Deshmane, Vikas Gulani, Mark A Griswold, and Nicole Seiberlich. Parallel mr imaging. *Journal of Magnetic Resonance Imaging*, 36(1):55–72, 2012.
- [2] Klaas P Pruessmann, Markus Weiger, Markus B Scheidegger, and Peter Boesiger. Sense: sensitivity encoding for fast mri. *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine*, 42(5):952–962, 1999.
- [3] Leslie Ying and Jinhua Sheng. Joint image reconstruction and sensitivity estimation in sense (jsense). *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine*, 57(6):1196–1202, 2007.
- [4] Peter Kellman, Frederick H Epstein, and Elliot R McVeigh. Adaptive sensitivity encoding incorporating temporal filtering (tsense). *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine*, 45(5):846–852, 2001.
- [5] Karl-Friedrich Kreitner, Bernd Romaneehsen, Frank Krummenauer, Katja Oberholzer, Lars Peter Müller, and Christoph Düber. Fast magnetic resonance imaging of the knee using a parallel acquisition technique (msense): a prospective performance evaluation. *European radiology*, 16(8):1659–1666, 2006.
- [6] Xiaojing Ye, Yunmei Chen, and Feng Huang. Computational acceleration for mr image reconstruction in partially parallel imaging. *IEEE Transactions on Medical Imaging*, 30(5):1055–1063, 2010.
- [7] Kristian Bredies, Karl Kunisch, and Thomas Pock. Total generalized variation. *SIAM Journal on Imaging Sciences*, 3(3):492–526, 2010.
- [8] Florian Knoll, Christian Clason, Kristian Bredies, Martin Uecker, and Rudolf Stollberger. Parallel imaging with nonlinear reconstruction using variational penalties. *Magnetic resonance in medicine*, 67(1):34–41, 2012.
- [9] Michael Lustig, David Donoho, and John M Pauly. Sparse mri: The application of compressed sensing for rapid mr imaging. *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine*, 58(6):1182–1195, 2007.
- [10] Dong Liang, Bo Liu, Jiunjie Wang, and Leslie Ying. Accelerating sense using compressed sensing. *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine*, 62(6):1574–1584, 2009.
- [11] Yan-Ran Li, Raymond H Chan, Lixin Shen, Yung-Chin Hsu, and Wen-Yih Isaac Tseng. An adaptive directional haar framelet-based reconstruction algorithm for parallel magnetic resonance imaging. *SIAM Journal on Imaging Sciences*, 9(2):794–821, 2016.
- [12] Yunsong Liu, Zhifang Zhan, Jian-Feng Cai, Di Guo, Zhong Chen, and Xiaobo Qu. Projected iterative soft-thresholding algorithm for tight frames in compressed sensing magnetic resonance imaging. *IEEE Transactions on Medical Imaging*, 35(9):2130–2140, 2016.
- [13] Xinlin Zhang, Hengfa Lu, Di Guo, Lijun Bao, Feng Huang, Qin Xu, and Xiaobo Qu. A guaranteed convergence analysis for the projected fast iterative soft-thresholding algorithm in parallel mri. *Medical Image Analysis*, 69:101987, 2021.

- [14] Il Yong Chun, Ben Adcock, and Thomas M Talavage. Efficient compressed sensing sense pmri reconstruction with joint sparsity promotion. *IEEE transactions on Medical Imaging*, 35(1):354–368, 2015.
- [15] Shanshan Wang, Sha Tan, Yuan Gao, Qiegen Liu, Leslie Ying, Taohui Xiao, Yuanyuan Liu, Xin Liu, Hairong Zheng, and Dong Liang. Learning joint-sparse codes for calibration-free parallel mr imaging. *IEEE transactions on medical imaging*, 37(1):251–261, 2017.
- [16] Jing Cheng, Sen Jia, Leslie Ying, Yuanyuan Liu, Shanshan Wang, Yanjie Zhu, Ye Li, Chao Zou, Xin Liu, and Dong Liang. Improved parallel image reconstruction using feature refinement. *Magnetic resonance in medicine*, 80(1):211–223, 2018.
- [17] Zhilang Qiu, Sen Jia, Shi Su, Yanjie Zhu, Xin Liu, Hairong Zheng, Dong Liang, and Haifeng Wang. Highly accelerated parallel mri using wave encoding and virtual conjugate coils. *Magnetic Resonance in Medicine*, 2021.
- [18] Martin Blaimer, Marcel Gutberlet, Peter Kellman, Felix A Breuer, Herbert Köstler, and Mark A Griswold. Virtual coil concept for improved parallel mri employing conjugate symmetric signals. *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine*, 61(1):93–102, 2009.
- [19] Saiprasad Ravishankar and Yoram Bresler. Mr image reconstruction from highly undersampled k-space data by dictionary learning. *IEEE transactions on medical imaging*, 30(5):1028–1041, 2010.
- [20] Zhen Chen, Chuanping Huang, and Shufu Lin. A new sparse representation framework for compressed sensing mri. *Knowledge-Based Systems*, 188:104969, 2020.
- [21] Xiaobo Qu, Yingkun Hou, Fan Lam, Di Guo, Jianhui Zhong, and Zhong Chen. Magnetic resonance image reconstruction from undersampled measurements using a patch-based nonlocal operator. *Medical image analysis*, 18(6):843–856, 2014.
- [22] Mark A Griswold, Peter M Jakob, Robin M Heidemann, Mathias Nittka, Vladimir Jellus, Jianmin Wang, Berthold Kiefer, and Axel Haase. Generalized autocalibrating partially parallel acquisitions (grappa). *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine*, 47(6):1202–1210, 2002.
- [23] Michael Lustig and John M Pauly. Spirit: iterative self-consistent parallel imaging reconstruction from arbitrary k-space. *Magnetic resonance in medicine*, 64(2):457–471, 2010.
- [24] Martin Uecker, Peng Lai, Mark J Murphy, Patrick Virtue, Michael Elad, John M Pauly, Shreyas S Vasanawala, and Michael Lustig. Espirit—an eigenvalue approach to autocalibrating parallel mri: where sense meets grappa. *Magnetic resonance in medicine*, 71(3):990–1001, 2014.
- [25] Martin Uecker and Michael Lustig. Estimating absolute-phase maps using esprit and virtual conjugate coils. *Magnetic resonance in medicine*, 77(3):1201–1207, 2017.
- [26] H Christian M Holme, Sebastian Rosenzweig, Frank Ong, Robin N Wilke, Michael Lustig, and Martin Uecker. Enlive: an efficient nonlinear method for calibrationless and robust parallel imaging. *Scientific reports*, 9(1):1–13, 2019.
- [27] Peter J Shin, Peder EZ Larson, Michael A Ohliger, Michael Elad, John M Pauly, Daniel B Vigneron, and Michael Lustig. Calibrationless parallel imaging reconstruction based on structured low-rank matrix completion. *Magnetic resonance in medicine*, 72(4):959–970, 2014.
- [28] K. H. Jin, D. Lee, and J. C. Ye. A general framework for compressed sensing and parallel mri using annihilating filter based low-rank hankel matrix. *IEEE Transactions on Computational Imaging*, 2(4):480–495, 2016.

- [29] J. Lyu, U. Nakarmi, D. Liang, J. Sheng, and L. Ying. Kernl: Kernel-based nonlinear approach to parallel mri reconstruction. *IEEE Transactions on Medical Imaging*, 38(1):312–321, 2019.
- [30] Martin Blaimer, Peter M Jakob, and Felix A Breuer. Regularization method for phase-constrained parallel mri. *Magnetic resonance in medicine*, 72(1):166–171, 2014.
- [31] Hemant K Aggarwal, Merry P Mani, and Mathews Jacob. Modl: Model-based deep learning architecture for inverse problems. *IEEE transactions on medical imaging*, 38(2):394–405, 2018.
- [32] Tim Salimans, Andrej Karpathy, Xi Chen, and Diederik P Kingma. Pixelcnn++: Improving the pixelcnn with discretized logistic mixture likelihood and other modifications. *arXiv preprint arXiv:1701.05517*, 2017.
- [33] Guanxiong Luo, Na Zhao, Wenhao Jiang, Edward S Hui, and Peng Cao. Mri reconstruction using deep bayesian estimation. *Magnetic resonance in medicine*, 84(4):2246–2261, 2020.
- [34] Christopher M Sandino, Peng Lai, Shreyas S Vasanawala, and Joseph Y Cheng. Accelerating cardiac cine mri using a deep learning-based espirit reconstruction. *Magnetic Resonance in Medicine*, 85(1):152–167, 2021.
- [35] Yan Yang, Jian Sun, Huibin Li, and Zongben Xu. Deep admm-net for compressive sensing mri. In *Proceedings of the 30th international conference on neural information processing systems*, pages 10–18, 2016.
- [36] Guang Yang, Simiao Yu, Hao Dong, Greg Slabaugh, Pier Luigi Dragotti, Xujiong Ye, Fangde Liu, Simon Arridge, Jennifer Keegan, Yike Guo, et al. Dagan: Deep de-aliasing generative adversarial networks for fast compressed sensing mri reconstruction. *IEEE transactions on medical imaging*, 37(6):1310–1321, 2017.
- [37] A. Sriram, J. Zbontar, T. Murrell, C. Zitnick, A. Defazio, and D. K. Sodickson. Grappanet: Combining parallel imaging with deep learning for multi-coil mri reconstruction. In *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14303–14310, Los Alamitos, CA, USA, jun 2020. IEEE Computer Society.
- [38] Mehmet Akçakaya, Steen Moeller, Sebastian Weingärtner, and Kâmil Uğurbil. Scan - specific robust artificial - neural - networks for k - space interpolation (raki) reconstruction: Database - free deep learning for fast imaging. *Magnetic Resonance in Medicine*, 81, 2019.
- [39] Shanshan Wang, Huitao Cheng, Leslie Ying, Taohui Xiao, Ziwen Ke, Hairong Zheng, and Dong Liang. Deepcomplexmri: Exploiting deep residual network for fast parallel mr imaging with complex convolution. *Magnetic Resonance Imaging*, 68:136–147, 2020.